Transformer のお勉強

April 25, 2026

目次

1. 研究背景
2. 手法
3. 結果と考察
4. まとめ
5. **Transformer** について

研究背景 - 大規模言語モデルの発展と課題

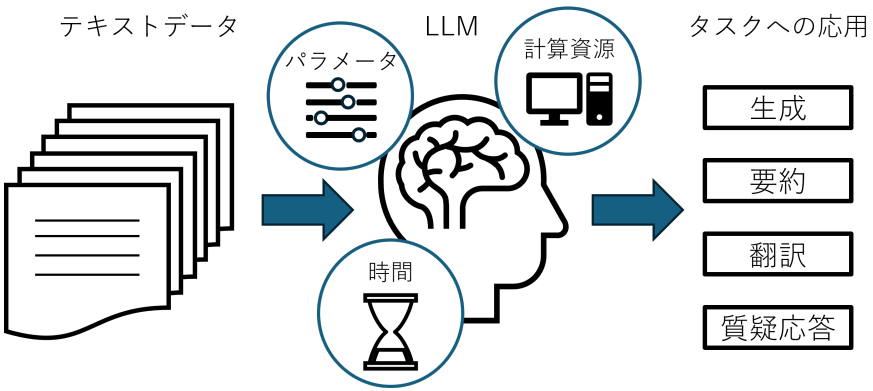

LLM の概要

大規模言語モデルの高性能化

- ディープラーニングや
  ビッグデータの恩恵を受け、
  大規模言語モデルは
  急速に発展している
- 最新モデルは様々なタスクに
  おいて人間に匹敵する
  言語能力を示す
- 多様なタスクで汎用的な
  言語能力を発揮

モデル規模拡大による弊害

- モデル規模 (計算量・データ量・パラメータ数) が年々増加
- 高性能化のために、モデル規模の拡大が必要である点が指摘される

研究背景 - 小規模言語モデル (SLM) の現在

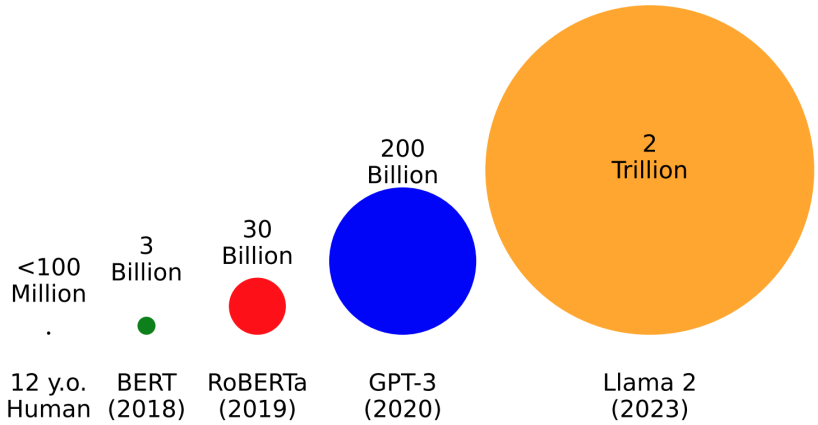

BabyLM Challenge [1]

「1 億語未満」のデータ制約化で効率的な言語獲得を目指すコンペティション

- 目的: スケーリング則に依存しない、学習効率の高いモデルの追求

既存 SLM 研究の課題 [2][3]

既存研究の多くが
Transformer ベースによる提案

- データの前処理や学習目標の工夫が中心
- モデル自体の計算コストは依然として高い現状

$\Downarrow$

低計算コストなモデル構造が必要

本研究のアプローチ: リザバー計算 **(Reservoir Computing)**

[1] Warstadt et al., Findings of the BabyLM Challenge, ACL, 2023.
[2] Kosmopoulou et al., Masked Diffusion Language Models, BabyLM Workshop, 2025.
[3] Păpușoi et al., A Comparison of Elementary Baselines, BabyLM Workshop, 2025.

研究背景 - リザバー計算 (RC) の概要

低計算コストを特徴とするリカレントニューラルネットワーク

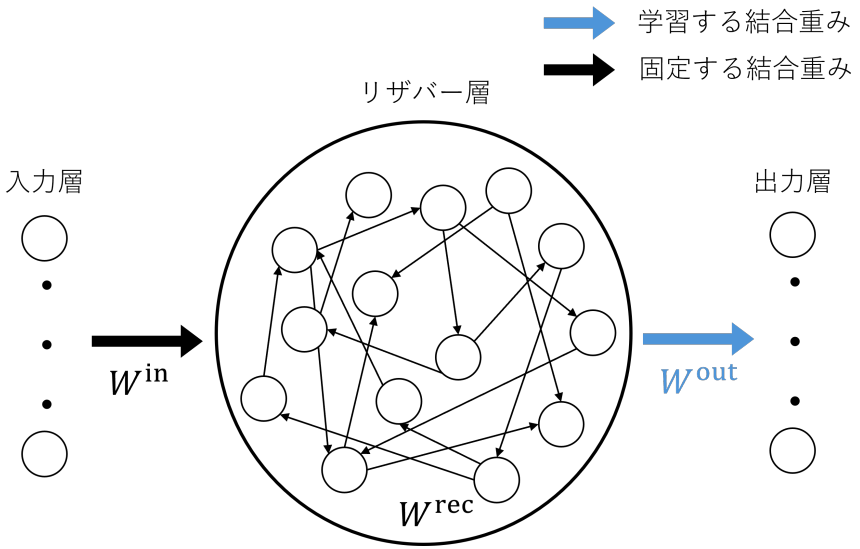

リザバー構造図

- 入力層・リザバー層の重みは固定
- 出力層の重みのみを学習
- 計算コストを大幅に削減できる
- 学習の安定性や実装の簡便性を持つ

研究背景 - リザバー計算を用いた SLM の可能性

リザバー計算を用いた小規模言語モデルの先行研究 (Ueda et al.)[4]

成果：Transformer に匹敵する性能

- リザバー層のニューロン数を **16,384** 以上に設定
- ゼロから学習した GPT-2 と同等、あるいは凌駕する文法能力 (BLiMP) を実証

課題：構造的な非効率性

1. **One-hot** 表現の課題:
   - 語彙間の意味的類似性を表現不可
   - 次元数増大に伴うリザバーの大規模化
2. 計算コストの課題:
   低計算コストを特徴とする RC であっても、大規模なニューロン数 ($\geq 16,000$) は高い計算コストを伴う

[4]Ueda, R. et al., Syntactic Learnability of Echo State Neural Language Models at Scale, Proceedings of NAACL 2025, 2025.

手法 - 提案モデルの概要

研究目的: 軽量化の検証

先行研究 (Ueda et al.) の課題である「高い計算コスト」に対し、分散表現を導入することで、約 1/16 のサイズでの言語獲得を目指す

	先行研究	本研究
入力	One-hot	分散表現
規模	$N_{\mathrm{rec}} \geq 16,384$	$N_{\mathrm{rec}} = 1,000$

⇒ 入力に意味情報を持たせることで、リザバー層の負担（記憶・識別）を軽減する。

モデル処理フロー

単語 w_t

↓ *Word2Vec (事前学習)*

入力 $\boldsymbol{d}(t)$

↓ *Input・Reservoir (固定)*

状態 $\boldsymbol{r}(t)$

↓ *Readout (学習)*

予測 $\boldsymbol{y}(t) \approx \boldsymbol{d}(t+1)$

構成の要点

- 入力層: 事前学習済みの分散表現を使用し、意味情報を入力 (重み固定)
- リザバー層: 入力を高次元非線形空間へ写像（重み固定）
- 出力層: 次の単語の分散表現を直接予測するように出力層の重みを学習

手法 - 入力表現の高度化

入力層の次元削減および意味情報の付与を目的に、Word2Vec[5] の Skip-gram アルゴリズムを採用する

Skip-gram の役割

中心語から文脈語を予測する学習を通じ、単語間の意味的類似性をベクトル空間上の距離として取得

「王」−「男」+「女」≈「女王」

本研究における設定

- パラメータ固定:
  RC 学習中は固定し、1 度の実行に書かる計算コストを抑制
- 次元数 (d_{emb}) の検証:
  32, 64, 128 の 3 パターンで比較し、表現能力と計算負荷のトレードオフを明らかにする

[5]Mikolov, T. et al., Efficient Estimation of Word Representations in Vector Space, Proceedings of ICLR, 2013.

手法 - リザバー計算の定式化

1. 状態更新

$$\boldsymbol{x}(t) = (1-\alpha)\boldsymbol{x}(t-1) + \alpha\Big(W^{\mathrm{in}}\boldsymbol{d}(t) + W^{\mathrm{rec}}\boldsymbol{r}(t-1)\Big)$$

$$\boldsymbol{r}(t) = \tanh(\boldsymbol{x}(t))$$

2. 出力

$$\boldsymbol{y}(t) = W^{\mathrm{out}}\boldsymbol{r}(t)$$

3. 重み更新

$$W^{\mathrm{out}}(t+1) = W^{\mathrm{out}}(t) + \frac{\mu}{B}\sum_{k=1}^{B}\boldsymbol{e}_k(t)\boldsymbol{r}_k(t)^{\top}$$

変数定義

- $\boldsymbol{d}(t)$: 入力ベクトル
- $\boldsymbol{r}(t)$: リザバー状態ベクトル
- $\boldsymbol{y}(t)$: 予測出力ベクトル
- $\boldsymbol{e}_k(t)$: 予測誤差 $(\boldsymbol{y}_{\mathrm{true}} - \boldsymbol{y})$
- α: 漏れ率
- μ: 学習率
- B: ミニバッチサイズ

学習対象

W^{out} のみ更新し、
$W^{\mathrm{in}}, W^{\mathrm{rec}}$ はランダムかつスパースに固定する

手法 - 学習の効率化

従来手法

- ターゲット：one-hot ベクトル
- 語彙数 V に比例した出力行列が必要
- 学習・推論共に V 次元の演算を伴う
- 計算量：$O(V)$ （高負荷）

提案手法

- ターゲット：分散表現ベクトル
- 埋め込み次元 d にのみ依存
- $d \ll V$
- 計算量：$O(d)$ （低負荷）

$\Downarrow$

ミニバッチ学習を用いた逐次的な重み更新により、
大規模なデータセットに対しても高速かつ省メモリな学習を実現

手法 - データセット

BabyLM Challenge 2025 Dataset

トレーニングデータ

Dataset	Description	Words
bnc_spoken	Dialogue	7.8M
childes	Child-directed speech	28.9M
gutenberg	Written English	26.4M
open_subtitles	Movie subtitles	20.0M
simple_wiki	Simple English	14.7M
switchboard	Dialogue	1.3M
Total		**99.0M**

テストデータ

Dataset	Description	Words
bnc_spoken	Dialogue	0.9M
childes	Child-directed speech	2.7M
gutenberg	Written English	2.4M
open_subtitles	Movie subtitles	1.9M
simple_wiki	Simple English	1.3M
switchboard	Dialogue	0.1M
Total		**9.5M**

手法 - データ前処理

語彙分布の適正化とノイズ除去

以下のルールに基づき抽象化・正規化・除去を行う

主な処理ルール

カテゴリ	変換例 → 処理後
抽象化	https://... → **URL** 1,000 / $50 → **NUM** 12:30 → **TIME**
正規化	café → cafe iPhone → iphone
除去	*Emphasis* → (削除) "Quote" → Quote

文字長制限: ≤ 13 文字

Length ≥ 14 の割合

指標	割合
語彙数	**6.03%**
出現数	**0.33%**

語彙総数に対して、一定の割合を示す一方で、実際の出現回数が極めて少ない

⇒ 学習効率の阻害要因とみなし、これらを含む文ごとデータセットから除外する。

手法 - 前処理によるデータセットの変化

処理前

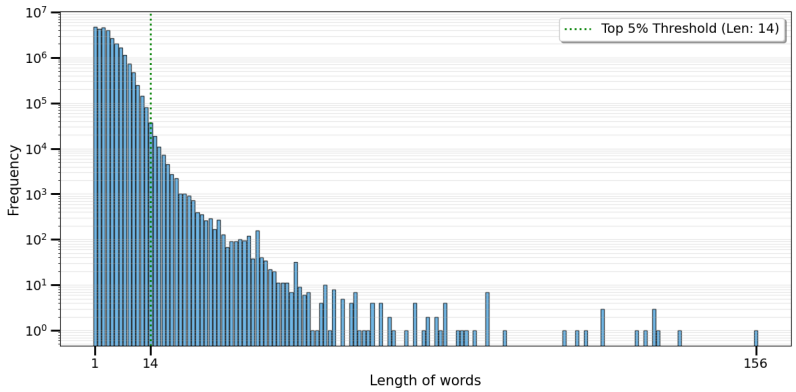

低頻出語・特殊記号を含む分布

処理後

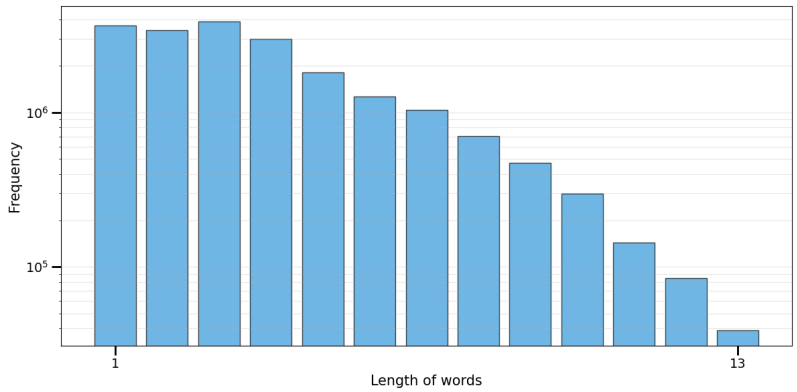

低頻出語・特殊記号を排除した分布

※ 縦軸が頻出度、横軸が単語長

処理前後の統計比較

項目	処理前	処理後
総単語数	26.9M	**25.1M**
語彙数	**520k**	**238k**
平均文字長	8.21	**7.45**
最大文字長	156	**13**

処理の要点

1. 最大文字長を 13 へ制限し、低頻度な長大語彙を排除
2. 語彙数を約 **54%**削減し、モデルの出力次元数を大幅に圧縮

手法 - 評価手法 (概要)

1. 次単語予測 (Perplexity)

予測の正確さ・不確実性

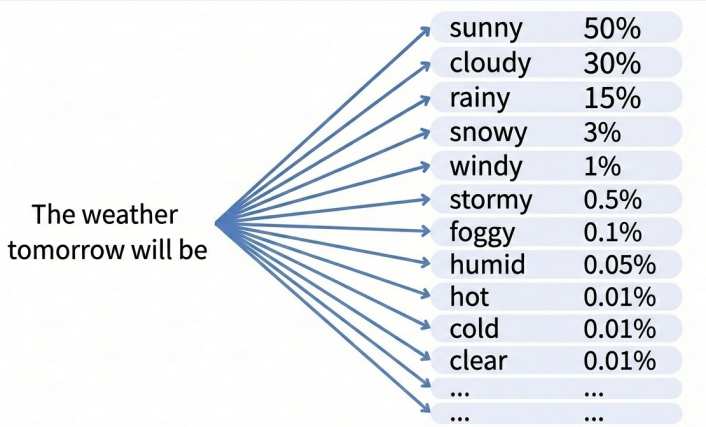

- モデルが予測する単語分布の不確実性を表す
- 値が小さいほど、予測性能が高い

2. 文法性判断 (BLiMP)

文法知識の獲得有無

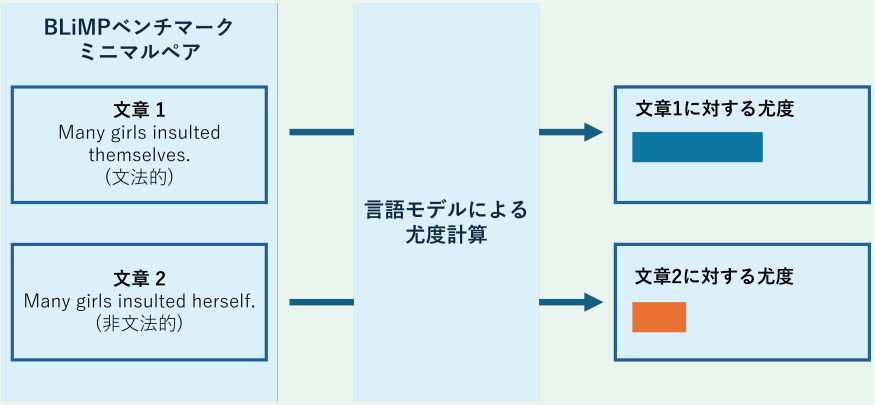

- モデルの文法理解力を測るベンチマーク
- 正解率が高いほど、文法理解が深い

手法 - 評価手法 - 次単語予測精度 (Perplexity)

予測ベクトル $\hat{\boldsymbol{y}}(t)$ と各語彙が持つ分散表現 $\boldsymbol{v}$ とのコサイン類似度に基づき確率分布を算出する

1. 類似度による確率定義

$$p(w_t|\boldsymbol{r}(t)) = \frac{\exp\left(\frac{\cos_\mathrm{sim}(\hat{\boldsymbol{y}}(t),\boldsymbol{v}_t)}{\tau}\right)}{\sum_{k=1}^{|V|}\exp\left(\frac{\cos_\mathrm{sim}(\hat{\boldsymbol{y}}(t),\boldsymbol{v}_k)}{\tau}\right)}$$

2. Perplexity (PPL) の算出

$$\mathrm{PPL}(W) = \exp\left(-\frac{1}{N}\sum_{t=1}^{N}\log p(w_t|\boldsymbol{r}(t))\right)$$

変数定義

- $\hat{\boldsymbol{y}}(t)$: 時刻 t における予測ベクトル
- $\boldsymbol{v}_t$: 正解単語 w_t の分散表現
- $\boldsymbol{v}_k$: 語彙集合 V 内の k 番目の分散表現
- τ: 温度パラメータ
- N: テストデータの総単語数-10

評価プロセス

- 文脈長: 10 単語
- 評価対象: $t = 1 \sim 10$ は内部状態の更新のみを行い、$t = 11$ 以降の単語を PPL 計算の対象とする。

手法 - 評価手法 - 文法性判断 (BLiMP)[5]

文法的に正当な文 (W_{good}) と誤った文 (W_{bad}) のペアに対し、
モデルの文スコアを比較して判定を行う

文スコア

文全体を通しての対数尤度の総和

$$\text{Score}(W) = \sum_{t=1}^{T-1} \log p(w_{t+1} \mid \boldsymbol{r}(t))$$

- T: 評価対象の文脈長 (文の単語数)
- $p(\cdot)$: PPL と同様に類似度に基づき算出

判定基準

正しい文法知識があれば、
正当な文の尤度が高くなる

正解条件:

$$\text{Score}(W_{\text{good}}) > \text{Score}(W_{\text{bad}})$$

評価対象データ:
英語の形態論・統語論・意味論に基づく 12 種類の言語現象（全 67 データセット）
各データセットは 1,000 組のミニマルペアから構成され、現象ごとの正解率を集計する

[5]Warstadt, A. et al., BLiMP: The Benchmark of Linguistic Minimal Pairs for English, MIT Press, 2020.

結果と考察 (1) - Perplexity

ρ および D_{emb} の変化に伴う PPL

ρ	0.80	0.85	0.90	0.95	1.00	1.05
D_{emb}	平均 Perplexity (PPL)					
32	7849.8	**7849.1**	7850.7	7854.9	7862.0	7871.7
64	9226.5	**9223.9**	9224.0	9227.2	9233.8	9243.8
128	**10464.8**	10467.4	10471.3	10476.3	10482.2	10488.9

※ 青で示すのは、各 D_{emb} における最良の結果
※ 値が小さいほど性能が高いことを示す

例: anymore , they re not trying . and we will (次単語: give)

$D_{\mathrm{emb}} = 32, \rho = 0.85$
(予測単語: [even] 、CosSim: 0.9685)

$D_{\mathrm{emb}} = 64, \rho = 0.85$
(予測単語: [just] 、CosSim:0.9504)

$D_{\mathrm{emb}} = 128, \rho = 0.80$
(予測単語: [,] 、CosSim: 0.9467)

最良設定: $D_{\mathrm{emb}} = 32, \rho = 0.85$

低次元かつ、やや短期記憶寄りの設定で最小値を示す

事象 1: D_{emb} の増加に伴う単調悪化

- 入力空間の疎性が特徴抽出の精度を著しく損なわせた可能性
- $D_{\mathrm{emb}} \uparrow$ に伴うコサイン類似度の低下は、予測ベクトルが語彙の意味内容を喪失し、出現頻度の高い「記号」へ出力が収束したことを裏付ける

事象 2: ρ の増加に伴う悪化

- 高 ρ 条件下での過去情報による影響が、直近の文脈依存的な予測を阻害するノイズとなった
- $\rho = 0.85$ 以降の精度悪化は、リザバーの保持情報量が読み出し層の最適処理範囲を超過したことことを示している可能性がある

結果と考察 (2) - BLiMP 全体傾向

ρ と D_{emb} の BLiMP 精度

ρ	0.80	0.85	0.90	0.95	1.00	1.05
D_{emb}	正解率 (%)					
32	55.68	55.57	55.48	55.49	**55.50**	**55.53**
64	**56.05**	**55.97**	**55.77**	**55.51**	55.26	54.93
128	55.07	55.01	54.92	54.82	54.70	54.66

※ 青で示すのは、各 ρ における最良の結果

最良設定: $D_{\mathrm{emb}} = 64, \rho = 0.80$

PPL の最適な次元数 ($D_{\mathrm{emb}} = 32$) より詳細な特徴表現 ($D_{\mathrm{emb}} = 64$) が有効であった

事象 1: 情報の精細化と限界

- $\rho < 1.0$ の条件下において $D_{\mathrm{emb}} = 32 \to 64$ は精度向上に寄与した
- 一方で、全 ρ において $D_{\mathrm{emb}} = 64 \to 128$ は精度低下を招く
- 適度な情報の精細化は表現能力を高める一方で、過度に行うと入力空間が疎になり、学習効率が悪化した可能性が示唆される

事象 2: 記憶容量のトレードオフ

- ρ の変化に対し、全体平均スコアの変動は極めて小さい
- 「短期記憶が有利に働くタスク」と「長期記憶が有利に働くタスク」の精度変動が互いに打ち消し合っているため（次スライドで詳述）

結果と考察 (3) - BLiMP 言語現象別傾向

長期記憶有意のタスク ($\rho \uparrow \Rightarrow$ 精度向上)

例: **Anaphor Agreement (照応形の一致)**

The senators ... hurt themselves. (適切)
The senators ... hurt himself. (不適切)
※先行詞と代名詞が数・性などにおいて一致するか

- 傾向: $\rho = 0.8 \rightarrow 1.05$ で精度向上 ($47.4\% \rightarrow 54.0\%$)
- 先行詞と代名詞の距離が遠いため、情報を長く保持できる高い ρ が有利に働く

短期記憶有意のタスク ($\rho \uparrow \Rightarrow$ 精度低下)

例: **NPI Licensing (否定極性項目)**

No students have ever been there. (適切)
Students have ever been there. (不適切)
※ ever などの単語が否定文のみで使用されているか

- 傾向: $\rho = 0.8 \rightarrow 1.05$ で精度低下 ($42.7\% \rightarrow 37.0\%$)
- 高い ρ では, 古い文脈がノイズとして残り、局所的な判断を阻害した

$\Downarrow$

固定された単一の ρ で、「短期記憶を要するタスク」と「長期記憶を要するタスク」を網羅することには構造的な限界がある

まとめ - 提案モデルの特性と限界

1. 予測性能 (PPL) の考察

- 「過度な詳細化 ($D_{\mathrm{emb}} = 128$)」は学習の妨げとなる可能性が示唆される
- $\rho \uparrow$ に伴う PPL 悪化は、遠い過去情報が残り、単語予測における「干渉」として作用した可能性が示唆される

2. 言語性能 (BLiMP) 全体像

- スコアの停滞: 全 ρ において平均正解率は 55%前後で飽和
- ρ の変化に対する平均値の変動が極めて小さいのは、タスク間の精度変動が互いに打ち消し合うため

3. 言語現象別の相反関係

- $\rho \uparrow$ に伴い精度が向上する長期記憶優位のタスクと精度が低下する短期記憶優位のタスクが確認された。また、評価指標によって適切な次元数も異なる。
- 単一の ρ で「短期記憶」と「長期記憶」を両立させることは困難

結論: リザバーの物理的特性（ρ）は言語現象ごとにトレードオフを引き起こす。
単一設定での全タスク網羅は困難であり、複数時間スケールの統合が必要

今後の展望

未検証のパラメータの変更

リーク率 α、ミニバッチサイズ B、学習率 μ など、本研究において固定していたパラメータについて検証する

Deep Reservoir・Attention Reservoir

- 多層リザバー: 異なる時間スケール（ρ）を持つ層を重ねることで、短期記憶優位のタスクと長期記憶優位のタスクに対する頑健性を示すことが期待される
- アテンション付きリザバー: アテンション機構の導入により、リザバー内部状態からタスクに重要な過去情報を動的に抽出することが期待される

Transformer の実装

現在の主流である Transformer の実装・比較を行い、データ制約下および低リソース環境における提案モデルの優位性を明確化する

Transformer

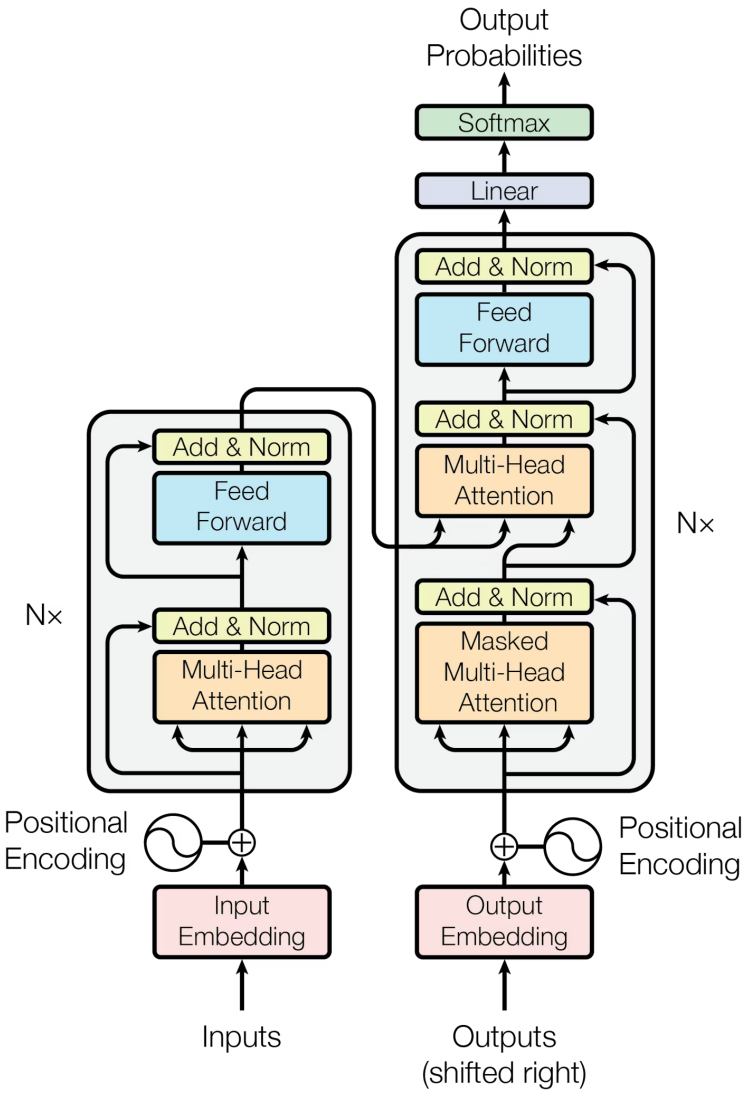

モデル

- RNN や CNN を使用せず、Attention のみで構成される
- 現行の LLM の多くが Transformer をベースとしている
- 翻訳タスクを解くモデルとして登場

[7]Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

Transformer

Encoder

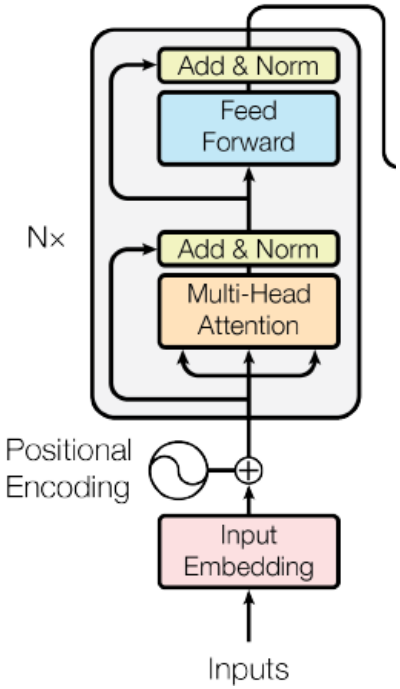

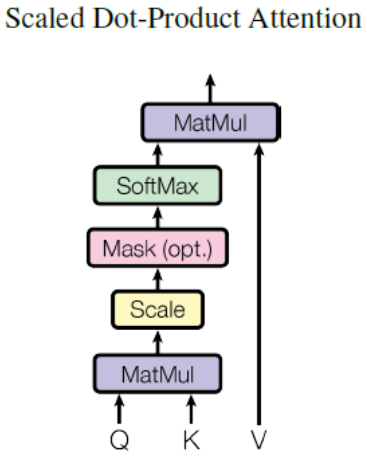

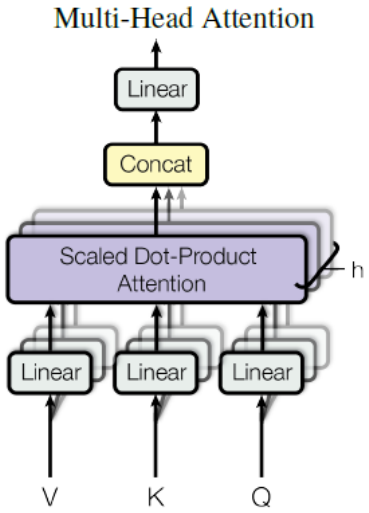

[7]Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

Transformer

Encoder - Input Enbedding

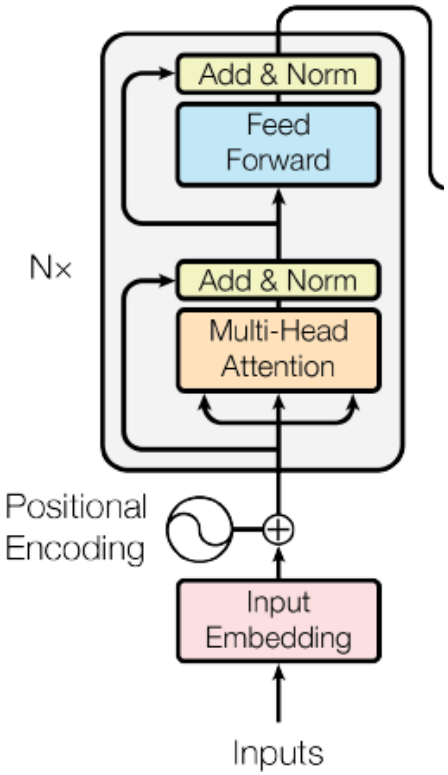

Input Embedding(埋め込み)

総トークン数を V として、V 次元の One-hot ベクトルを埋め込みに変換する行列 E を定義

$$E \in \mathbb{R}^{V \times d_{\text{model}}}$$

t=[0,0..,1,..,0,0] を, 第 k 成分のみ 1 で、他は全て 0 の One-hot ベクトルとする

$$tE = d$$

d は E の k 行目と一致する横ベクトル

[7]Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

Transformer

Encoder - Positional Encoding

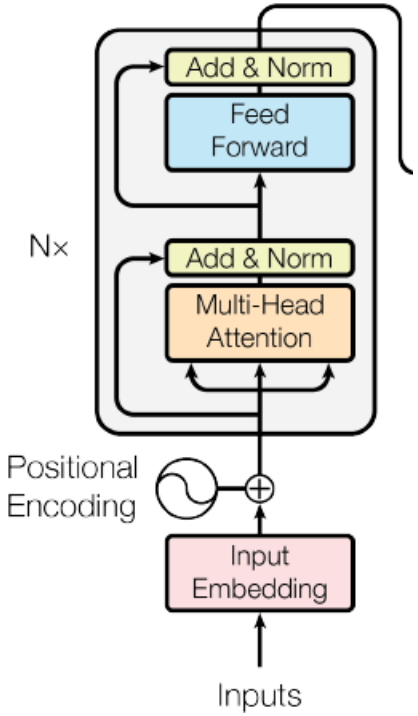

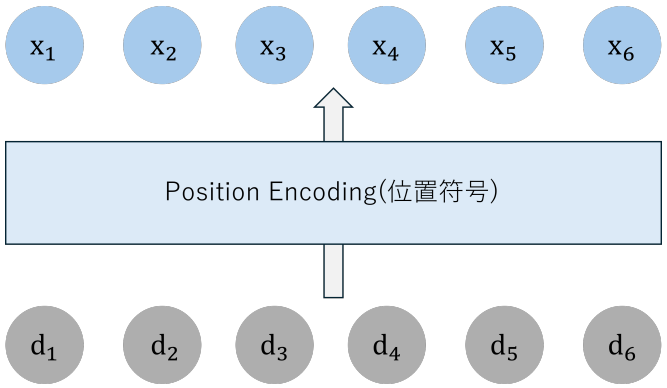

位置符号

入力埋め込みベクトル d に位置符号と呼ばれるベクトルを加算
→語順の情報が付与される

正弦関数と余弦関数を用いて位置ごとに異なる固有のパターンをもつベクトルを生成し、d に直接加算するらしい

[7]Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

Transformer

Encoder - Scaled Dot-Product Attention

Scaled Dot-Product Attention

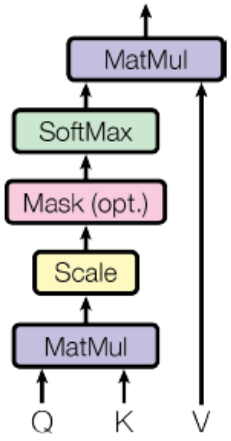

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

処理フロー

- **1. MatMul**: Q と K の内積により単語間の相関（スコア）を算出
- **2. Scale**: $\sqrt{d_k}$ で除算。d_k 増大による勾配消失を防止
- **3. Softmax**: スコアを合計 1 の確率（重み）に正規化
- **4. MatMul**: 重みに基づき V を足し合わせ、文脈を集約

変数	名称	イメージ・定義
$Q \in \mathbb{R}^{n \times d_k}$	Query	「何に注目したいか」
$K \in \mathbb{R}^{n \times d_k}$	Key	「どのような情報を持っているか」
$V \in \mathbb{R}^{n \times d_v}$	Value	実際に抽出される「情報」
n	シーケンス長	入力トークン数
d_k	次元数	Q, K の次元数
d_v	次元数	V の次元数
softmax	関数	正規化する処理

Transformer

Encoder - Scaled Dot-Product Attention

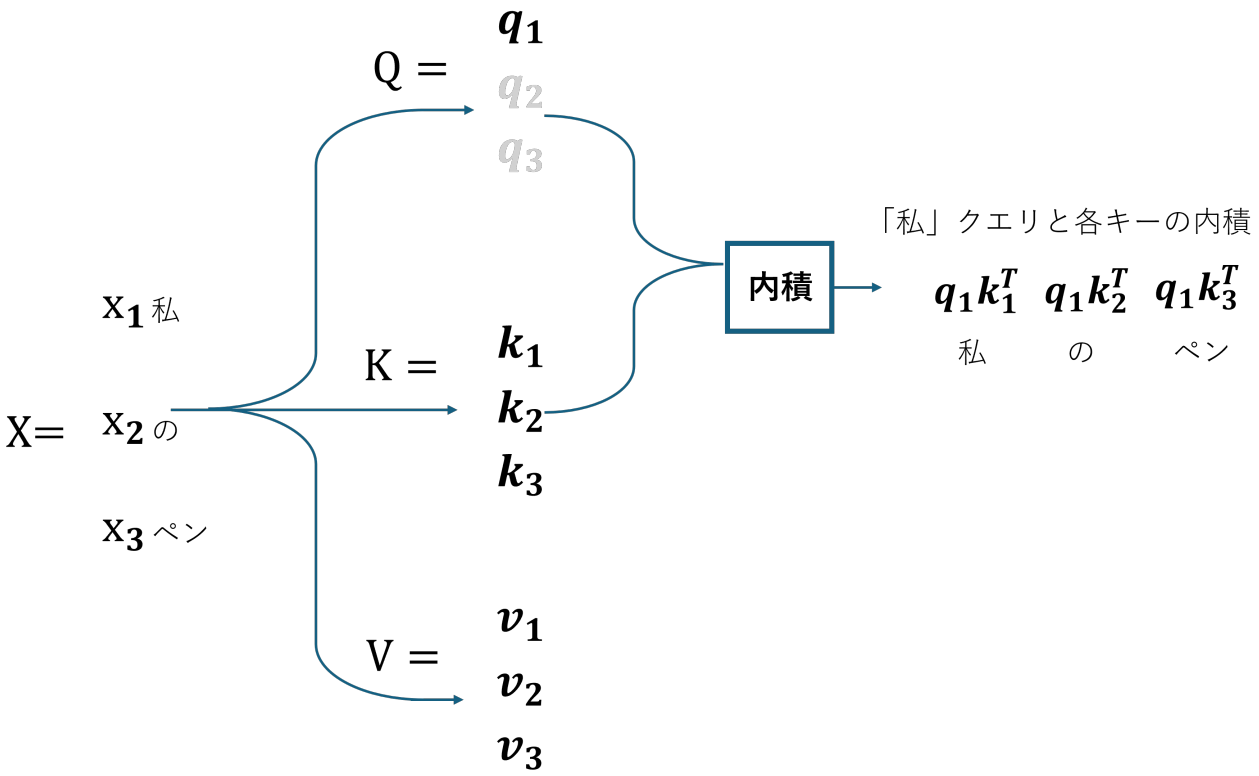

Query(注目したい単語) と各 Key(文中の各単語) がどれだけ関連しているか (類似度) を算出

[7]Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

Transformer

Encoder - Scaled Dot-Product Attention

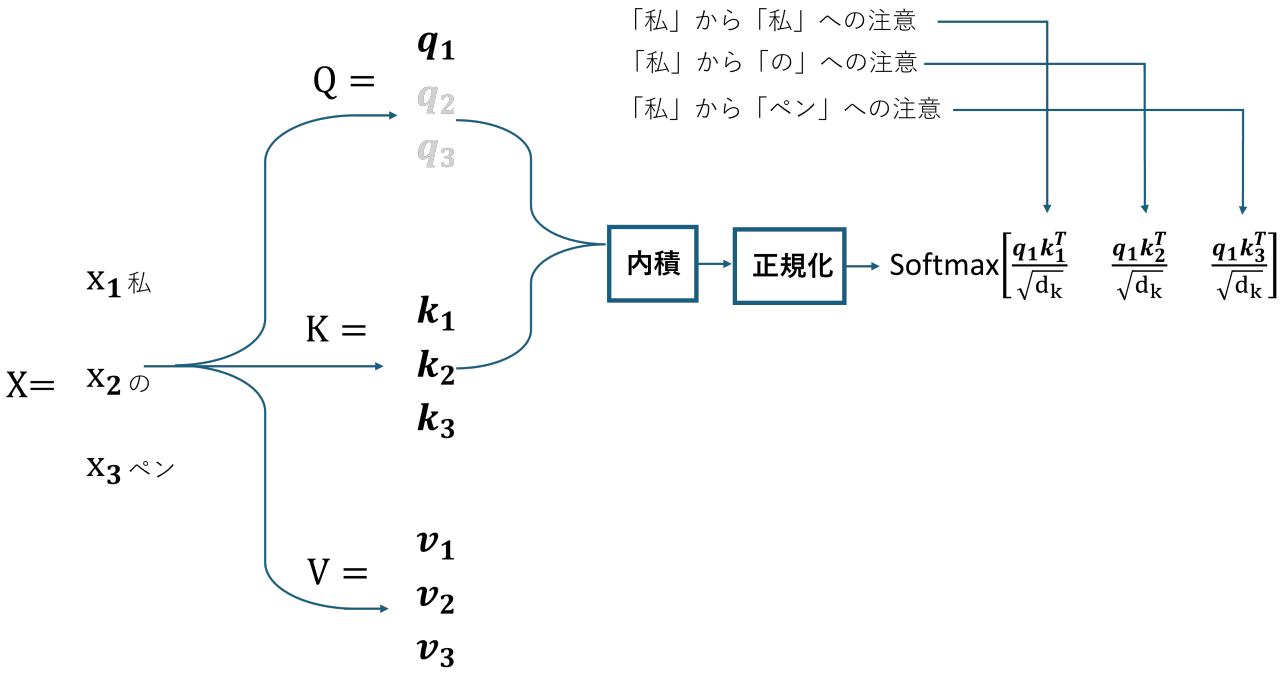

Query と各 Key の内積を正規化したものを「対象の単語が周りの各単語をどれほど注視しているか」の指標とみなす (=注意重み)

[7]Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

Transformer

Encoder - Scaled Dot-Product Attention

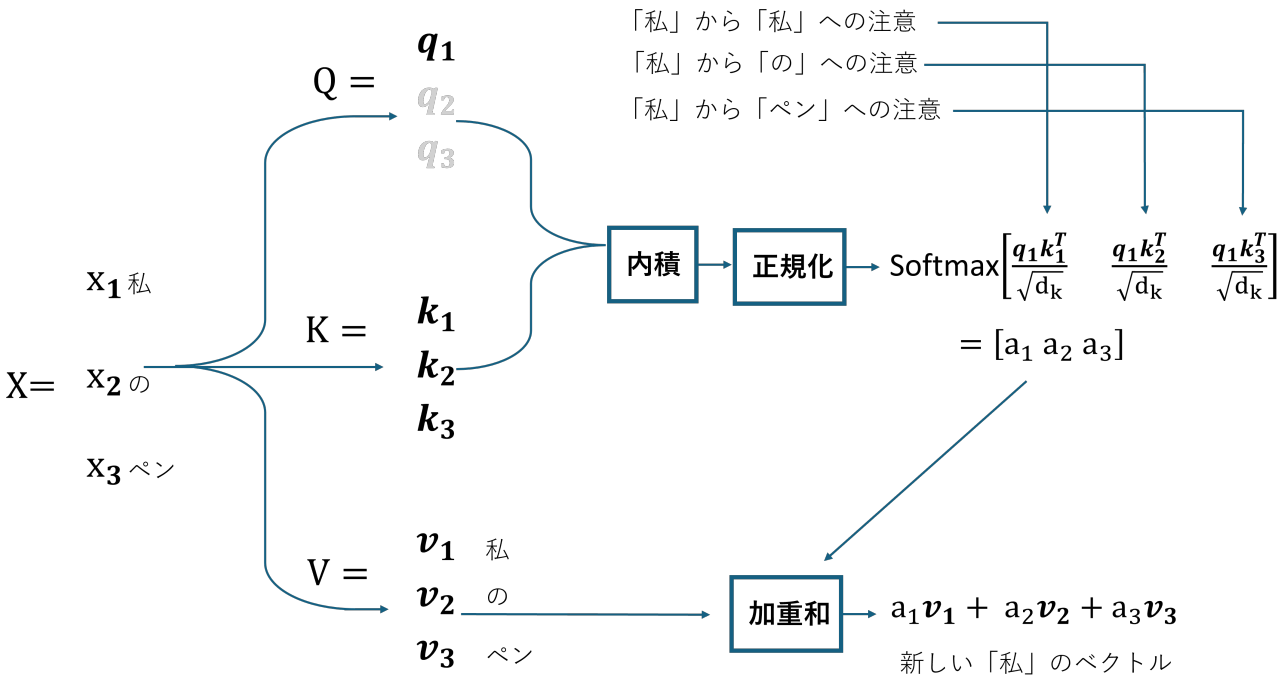

注意重みで重み付けされた Value の和を計算することで「私」のベクトルに周辺の単語情報が付加される

[7]Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

Transformer

Encoder - Scaled Dot-Product Attention

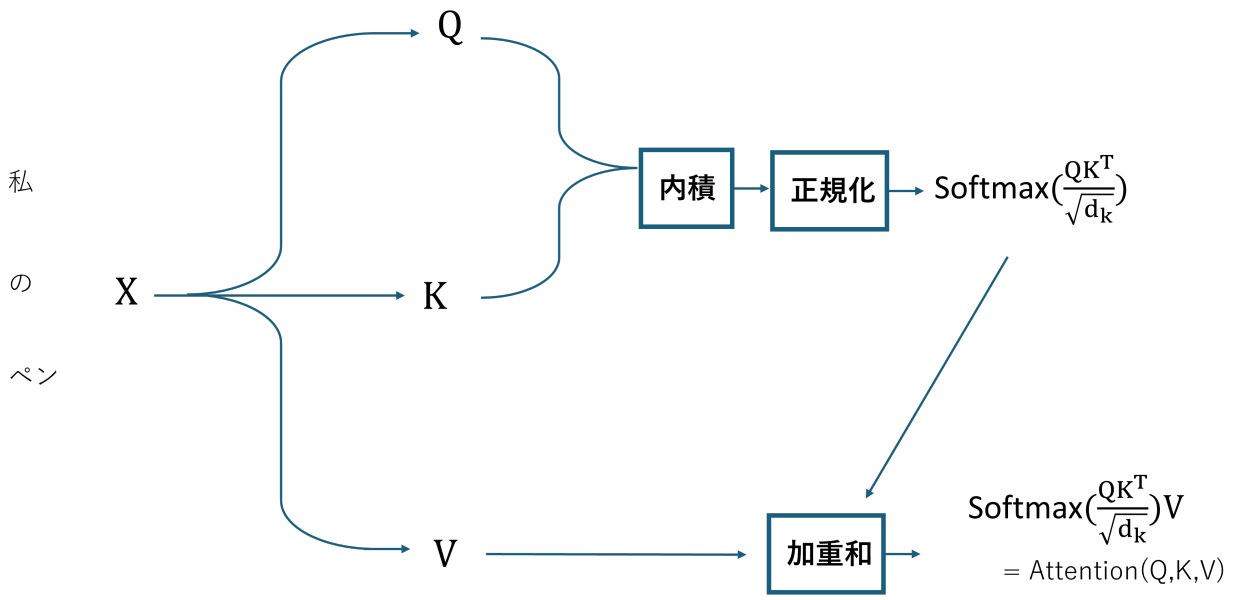

x_1、x_2、x_3 の更新は独立しているため並列化可能
$\rightarrow x_1$ を行列 X の 1 列目の要素のようにみなすと X 全体の更新を Attention(Q,K,V) で行える

[7]Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

Transformer

Encoder - Multi-Head Attention

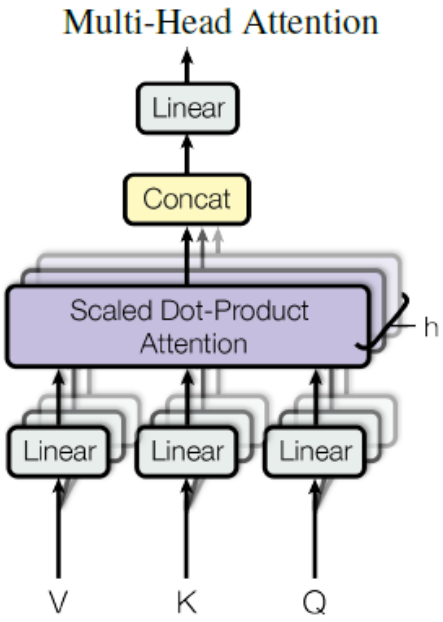

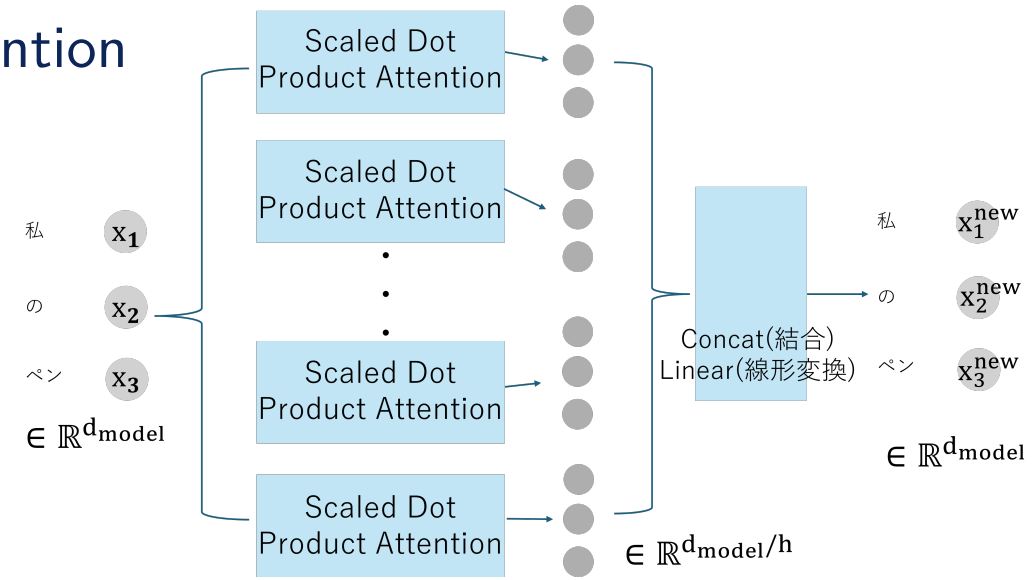

$$\text{Multi Head}(Q, K, V) = \text{Concat}(\text{head}_1, , , \text{head}_h)W^o$$
$$\text{head}_i = \text{Attentio}(QW_i^Q, KW_i^K, VW_i^V)$$

変数	名称
$W^Q, W^K \in \mathbb{R}^{d_{model} \times d_k}$	Q, K の投影用の重み
$W^V \in \mathbb{R}^{d_{model} \times d_v}$	V の投影用の重み
$W^O \in \mathbb{R}^{hd_v \times d_{model}}$	出力統合用の重み
d_k, d_v	各ヘッドの次元数
d_{model}	埋め込みベクトルの次元数
h	ヘッド数

[7]Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

Transformer

Encoder - Add & Norm

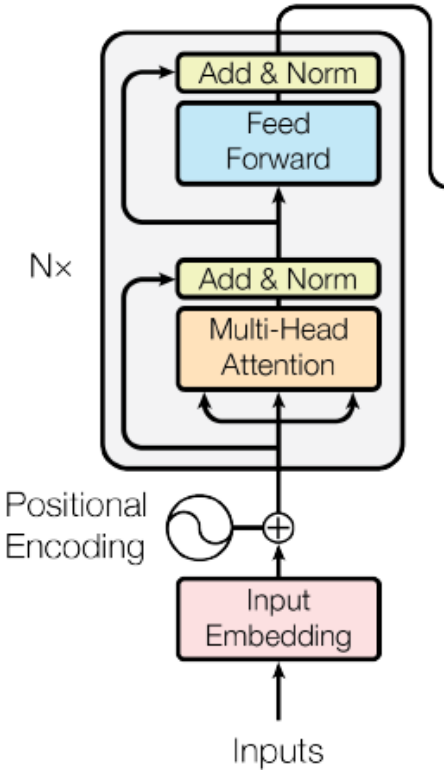

Residual Connection & Layer Norm

各サブレイヤの出力を以下の処理を行う

$$\text{Output} = \text{LayerNorm}(x + \text{Sublayer}(x))$$

- **Add (Residual)**: 前の層の出力 Sublayer(x) へ入力 x を直接足す
  →勾配消失を防ぎ、深い層でも学習が安定
- **LayerNorm**: 特徴ベクトルの平均を 0、分散を 1 に正規化
  →学習が高速化・安定化

[7] Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

Transformer

Encoder - Feed Forward Network

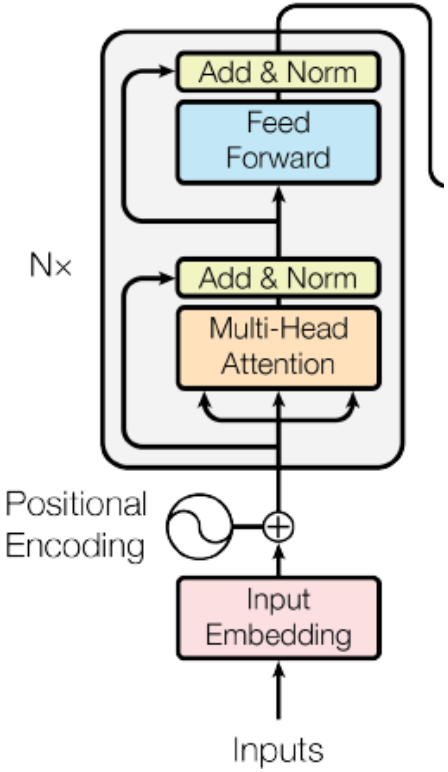

Position-wise Feed Forward (FFN)

$$\mathrm{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

変数・次元数定義：

- $W_1 \in \mathbb{R}^{d_{\mathrm{model}} \times d_{ff}}$ (512 → 2048)
- $W_2 \in \mathbb{R}^{d_{ff} \times d_{\mathrm{model}}}$ (2048 → 512)

Attention 層から出力された関係性情報を、非線形変換し、より抽象度の高い特徴を抽出する

[7] Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

参考文献

[1] Warstadt, A. et al., Findings of the BabyLM Challenge: Sample-Efficient Pretraining on Developmentally Plausible Corpora, Association for Computational Linguistics, 2023.

[2] Kosmopoulou, D. et al., Masked Diffusion Language Models with Frequency-Informed Training, Proceedings of the First BabyLM Workshop, Association for Computational Linguistics, 2025.

[3] Păpușoi, R. et al., A Comparison of Elementary Baselines for BabyLM, Proceedings of the First BabyLM Workshop, Association for Computational Linguistics, 2025.

[4] Ueda, R. et al., Syntactic Learnability of Echo State Neural Language Models at Scale, Proceedings of NAACL 2025, 2025.

[5] Warstadt, A. et al., BLiMP: The Benchmark of Linguistic Minimal Pairs for English, MIT Press, 2020.

[6] Mikolov, T. et al., Efficient Estimation of Word Representations in Vector Space, Proceedings of ICLR, 2013.

[7] Vaswani, A. et al., Attention Is All You Need, Proceedings of the 31st International Conference on Neural Information Processing Systems, pp.6000 - 6010, 2017.

補足資料 - **Skipgram** のパラメータ設定

Word2Vec の学習パラメータ

パラメータ	意味	設定値
Algorithm	学習アルゴリズム	Skip-gram
D_{emb}	ベクトルの次元数	32, 64, 128
window	コンテキストの窓幅	3
$\mathrm{min_count}$	出現頻度の閾値	5
η	初期学習率	5.0×10^{-2}
η_{min}	最小学習率	1.0×10^{-3}
Epochs	学習エポック数	1

補足資料 - RC のパラメータ設定

RC のハイパーパラメータおよび最適化アルゴリズム

カテゴリ	パラメータ	意味	設定値
RC	N_{in}	入力層の次元数	32, 64, 128
	N_{rec}	リザバー層のニューロン数	1000
	W^{in}	入力重み行列の初期分布	$\mathrm{Uniform}(-0.1, 0.1)$
	W^{rec}	再帰重み行列の初期分布	$\mathrm{Uniform}(-1.0, 1.0)$
	$\rho(W^{\mathrm{rec}})$	スペクトル半径	0.80, 0.85, 0.90, 0.95, 1.00, 1.05
	$\alpha \in (0, 1]$	リークレート	0.5
	f	活性化関数	$\tanh$
学習設定	Algorithm	最適化アルゴリズム	ミニバッチ LMS 法
	μ	学習率	1.0×10^{-3}
	B	ミニバッチサイズ	128
	L	入力文脈長	10
	Epochs	学習エポック数	1

補足資料 - 12 の言語現象と難易度

Type A: 局所的・形態的制約

単語間の距離が近く、パターンマッチングで解ける可能性が高い現象。

- **Determiner-Noun** (限定詞-名詞)
  *this dog / *these dog*
- **Subject-Verb** (主語-動詞)
  *dogs run / *dogs runs*
- Anaphor Agreement (照応形)
- Irregular Forms (不規則変化)
- Argument Structure (項構造)

Type B: 大域的・意味的制約

文全体の構造理解や、記憶の保持が必要な高難度な現象。

- **Island Effects** (島の制約)
  複雑な構文における移動の禁止
- **NPI Licensing** (否定極性項目)
  否定語と *any* 等の呼応
- **Quantifiers** (数量詞の論理)
- Binding / Control / Ellipsis / Filler-Gap

仮説: リザバー計算は短期記憶 (Type A) には強いが、論理構造 (Type B) には苦戦するのではないか？

先行研究の知見

- 易: 限定詞と名詞の一致（局所的な情報で解決可能）
- 難: 島の制約（複雑な統語構造の理解が必要）

補足資料 -「スケーリング」から「少量かつ高品質」へのシフト

Kaplan ら [1]、Hoffmann ら [2]

- モデルパラメータ N の拡大を重視すべき (2020)
- パラメータ N とデータ量 D を等倍で拡大すべき (2022)

Gunasekar ら [3]

- 従来の LLM が Web 上の雑多な低品質データで学習している点を指摘
- 質の高いデータを選別・合成
- **1/100 のデータ量**で、大規模モデルに匹敵するコード生成能力を達成 (2023)

新たな潮流

「限られた資源・データ」でいかに性能を出すか？ → **BabyLM Challenge** へ

[1]Kaplan, J. et al., Scaling Laws for Neural Language Models, arXiv preprint, arXiv:2001.08361, 2020.
[2]Hoffmann, J. et al., Training Compute-Optimal Large Language Models, arXiv preprint, arXiv:2203.15556, 2022.
[3]Gunasekar, S. et al., Textbooks Are All You Need, arXiv preprint, arXiv:2306.11644, 2023.

補足資料 - 提案モデルの効率性

1. 標準的な LLM

Transformer 等

- 更新対象:
  全ブロック (同時更新)
- 出力層の次元:
  語彙数 V ($\approx 50k$)
- 計算量:
  $O(L^2 \cdot d_m + V)$
- 構造イメージ:
  ↑ 出力層 (V: 更新)
  ↑ 中間ブロック (更新)
  ↑ 埋め込み層 (更新)

2. 先行研究 [7]

分類ベース **RC**

- 更新対象:
  出力層のみ (単一)
- 出力層の次元:
  語彙数 V ($\approx 50k$)
- 計算量:
  $O(L \cdot N_{rec}^2 + V)$
- 構造イメージ:
  ↑ 出力層 (V: 更新)
  ↑ リザバー (固定)
  ↑ 入力層 (固定)

3. 提案手法

回帰ベース **RC**

- 更新対象:
  出力層のみ (分離)
- 出力層の次元:
  分散表現 d (≈ 128)
- 計算量:
  $O(L \cdot N_{rec}^2 + \mathbf{d})$
- 構造イメージ:
  ↑ 出力層 (d: 更新)
  ↑ リザバー (固定)
  ↑ **W2V (事前学習済)**

提案モデルの手法:

1. 事前学習: 学習フェーズを分けて一度の実行でかかる計算コストを分割している
2. **RC** 学習: 正解ベクトルとの二乗誤差を最小化する「低次元回帰」へと問題を簡略化

補足資料 - 言語現象ごとの精度の二極化

単純な共起で解ける問題は完璧に正解する一方、構造理解を要する問題は、ランダム (50%) を大幅に下回る結果となった

得意: 局所的な語彙一致 ($\approx 100\%$)

Task	Model	Human
Binding(Principle-A)	**100.0%**	98.0%
Wh-questions	**100.0%**	98.0%

現象: 線形距離の近接性

- **Binding (束縛)**: 先行詞と再帰代名詞 (*himself* 等) が同一節内にあり、かつ距離が近いケース
- 「主語 → 動詞 → 再帰代名詞」という単語列パターンを統計的に識別できている

苦手: 階層構造と論理 ($\approx 0\%$)

Task	Model	Human
Wh-vs-That (gap)	**0.0%**	77.0%
Only-NPI (scope)	**0.1%**	72.0%

現象: 構造的依存関係

- **NPI**（否定極性項目）: NPI（否定極性項目）の正誤判定には、単語の距離ではなく「否定語が構文木の上位にあるか」という階層構造の理解が必要
- 0%に近いスコアは、モデルが単語列パターンのみを学習し、階層構造を理解できていないことを示す

Attention-Enhanced Reservoir Computing

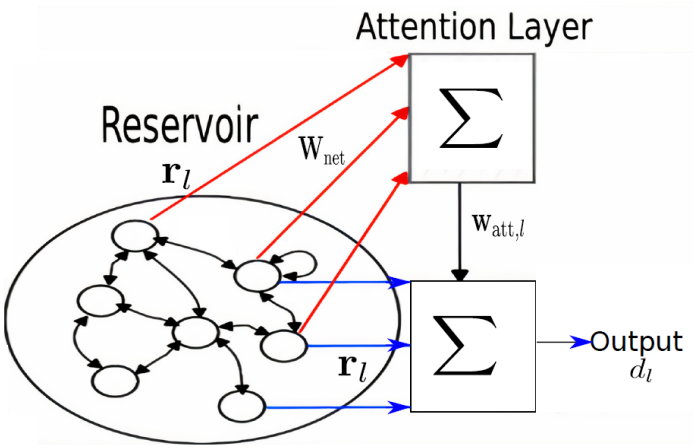

アテンション強化型リザバーの概要図

アテンション機構とは

- リザバー状態 $\boldsymbol{r}(t)$ に基づき、出力重みを動的に計算する仕組み
- 毎時刻で「リザバーのどのノードを優先すべきか」を適応的に決定

手法 - アテンション強化型リザーバの定式化

1. アテンション重みの動的生成

$$\boldsymbol{h}(t) = \mathrm{ReLU}(W_1 \boldsymbol{r}(t) + \boldsymbol{b}_1)$$
$$W_{\mathrm{att}}(t) = W_2 \boldsymbol{h}(t) + \boldsymbol{b}_2$$

※ $W_{att}(t)$ は時刻 t ごとに計算される行列

2. 出力

$$\boldsymbol{y}(t) = W_{\mathrm{att}}(t) \boldsymbol{r}(t)$$

3. パラメータ更新 (勾配降下法)

$$W_{\mathrm{net}} \leftarrow W_{\mathrm{net}} - \gamma \nabla \mathcal{L}$$

$$\mathcal{L} = \mathrm{NRMSE}(\boldsymbol{y}, \boldsymbol{y}_{\mathrm{true}})$$

追加・変更変数定義

- W_{net}: 学習対象 $\{W_1, W_2, \boldsymbol{b}_1, \boldsymbol{b}_2\}$ の総称
- $W_{\mathrm{att}}(t)$: アテンション重み
- $\boldsymbol{h}(t)$: 隠れ層の特徴ベクトル
- γ: 学習率
- $\mathcal{L}$: 損失関数 (正規化 RMSE)

Transformer

Encoder - Positional Encoding

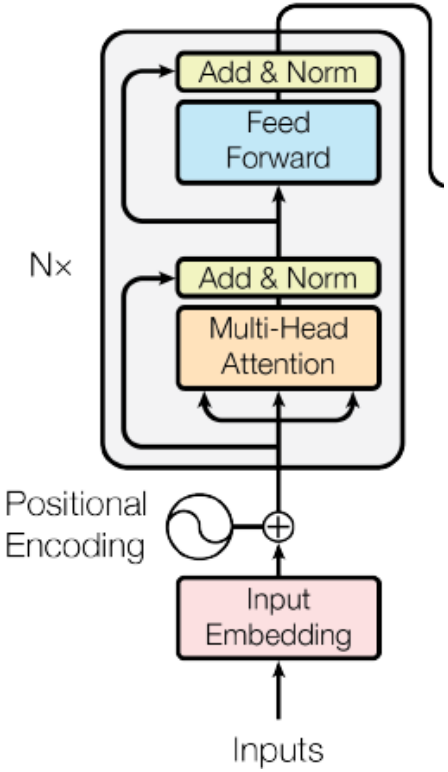

Positional Encoding(位置エンコーディング)

単語の順序情報を付与するため、埋め込みベクトルに加算する。

$$PE_{(pos,2i)} = \sin(pos/10000^{2i/d_{\text{model}}})$$

$$PE_{(pos,2i+1)} = \cos(pos/10000^{2i/d_{\text{model}}})$$

変数定義：

- pos: 文中でのトークンの位置（0, 1, ...）
- i: 次元のインデックス（0 から $d_{\text{model}}/2$ まで）
- d_{model}: モデルの次元数（512）

役割：RNN のような逐次処理を行わないため、絶対的・相対的な位置関係を正弦波の周期性により表現する。